

Maschinelles Lernen Blatt 3


Nikolas Zeitler, Joshua Hartmann, Alexander Diegel

May 12, 2016

a) Einlesen der Daten.

siehe Matlab-File.

b) Die Daten zu jeder Kenngröße jeder Schwertlilienart aus den Trainingsdaten sollen in einem Histogramm veranschaulicht werden. Höchstens sechs Sätze sollen zudem Auffälligkeiten in den Daten beschreiben



Die meisten Histogramme ähneln einer gauss'schen Normalverteilung. Die Gattung Setosa bildet hinsichtlich der sepalen Länge die kleinste Art (der Erwartungswert dieser Größe ist ca. 5, wie in Aufgabe c) dargestellt wird, Verginica bildet hat für diese Größe mit 6.6 den größten Erwartungswert). Bei der Gattung Setosa gibt es eine Lücke in den Histogrammen für die sepalen und petale Breite- während es bei der sepalen Länge zufall sein kann, dass zwischen 2,5 und 3 keine Werte gemessen wurden (vllt. hätte man einfach mehr Messungen durchführen müssen), ist die Lücke bei der petalen Breite auffälliger, da hier ein Wert zwischen 27 und 7 erwartet werden würde (ginge man von einer Normalverteilung dieser Eigenschaft aus). Ebenfalls die mit Abstand kleinste Art ist die Setosa für die petale Breite. Die Gattung Versicolor hat einen großen Ausschlag bei der sepalen Breite (ca. bei 2,75-3 sie ist die kleinste der drei Arten für dieses Merkmal). Die Gattung Verginica ist die größte aller drei Arten bei allen Merkmalen (wenn die Erwartungswerte betrachtet werden.) Sie hat aber u.a. das breiteste Spektrum z.B. bei der sepalen Länge.

c) Für jede Kenngröße jeder Schwertlilienart sind anschließend sowohl der Mittelwert als auch die Varianz für die Trainingsdaten zu bestimmen.

meanSetosa = [5.04, 3.54, 1.47, 0.25]
meanVersicolor = [5.9, 2.75, 4.2, 1.3]
meanVerginica = [6.592, 2.98, 5.4975, 2.022]


varSetosa = [0.13, 0.15, 0.035, 0.012]
varVersicolor = [0.2, 0.09, 0.22, 0.04]
varVerginica = [0.36, 0.1, 0.3, 0.08]

d) Likelihoods - siehe Matlab-File

e) Maßzahlen


	Setosa	Versicolor	Verginica
true positive	10	9	9
true negative	20	19	19
false positive	0	1	1
false negative	0	1	1

f) Kenngrößen



Die Gattung *Setosa* ist gut gegenüber den anderen Arten in den ersten drei Plots abzugrenzen. Das kommt daher, dass diese Pflanze die schmalste ist. Beim Plot sepale Länge vs. sepale Breite ist die Unterscheidung nicht mehr ganz so deutlich zu erkennen, das kommt daher, dass sich die sepalen Längen und Breite aller drei Arten zum Teil überschneiden. Dieser Plot zeigt des Weiteren Unterscheidungsschwierigkeiten zwischen *Virginica* und *Versicolor* auf. Diese Durchmischung zeigt sich bereits teilweise in den ersten drei Plots, wird in diesem aber besonders deutlich. Das liegt daran, dass sich *Virginica* und *Versicolor* (bzw. deren Wertebereiche in den folgenden Eigenschaften) bei sepalen Länge und Breite sowie petalen Länge ähnlich sind (es gibt Überschneidungen). Zu Unterscheiden sind in diesem Plot lediglich *Setosa* bei sehr kleinen sepalen Längen und *Virginica* bei sehr großen sepalen Längen.

g) Multivariate Normalverteilung- siehe Matlab-File



Erklärung der Änderungen:

Nach der Klassifikation mit der Annahme, dass es sich bei den Kenndaten um eine multivariate Normalverteilung (und keine unabhängigen Daten) handelt, konnten alle Schwertlinien korrekt klassifiziert werden. Die getroffene Annahme scheint die Realität besser zu treffen.

Zuvor wurden geringe Klassifikationsfehler bei Versicolor und Virginica gemacht (10% bzw. 5%). (Diese Aussagen sind jedoch mit Vorsicht zu genießen, da es sich um einen sehr kleinen Datensatz handelt.)